

Hierarchical Clustering

Fachliche Dokumentation und Methodenleitfaden

1 Einführung

Hierarchisches Clustering ist ein Verfahren des unbeaufsichtigten maschinellen Lernens (Unsupervised Learning), das Datenpunkte anhand ihrer Ähnlichkeit in eine verschachtelte Baumstruktur – das sogenannte **Dendrogramm** – einordnet. Im Gegensatz zu partitionierenden Verfahren wie K-Means muss die Anzahl der Cluster nicht vorab festgelegt werden; sie ergibt sich aus der Analyse des Dendrogramms.

Man unterscheidet zwei grundlegende Strategien:

Agglomerativ (Bottom-Up)

Beim agglomerativen Ansatz startet jeder Datenpunkt als eigenständiges Cluster. In jedem Schritt werden die zwei Cluster mit dem geringsten Abstand zu einem neuen Cluster verschmolzen. Dieser Vorgang wiederholt sich, bis sämtliche Datenpunkte in einem einzigen Cluster vereint sind. Der agglomerative Ansatz ist in der Praxis die mit Abstand am häufigsten eingesetzte Variante und wird im Folgenden ausführlich behandelt.

Divisiv (Top-Down)

Der divisive Ansatz arbeitet umgekehrt: Ausgangspunkt ist ein einziges Cluster, das alle Datenpunkte enthält. Dieses wird schrittweise in immer kleinere Teilgruppen zerlegt. Da in jedem Schritt sämtliche möglichen Teilungen bewertet werden müssen, steigt die Laufzeitkomplexität exponentiell an ($O(2^n)$). In der Praxis ist dieses Verfahren daher nur für sehr kleine Datensätze geeignet. Der DIANA-Algorithmus (Divisive Analysis) bietet eine heuristische Vereinfachung, kommt aber selten zum Einsatz.

2 Linkage-Methoden

Die zentrale Frage beim agglomerativen Clustering lautet: *Wie wird der Abstand zwischen zwei Clustern gemessen?* Die Antwort darauf liefert die sogenannte Linkage-Methode. Sie bestimmt maßgeblich die Form, Größe und Qualität der resultierenden Cluster und sollte stets bewusst auf die Datenstruktur abgestimmt werden.

2.1 Single Linkage (Nächster Nachbar)

Beim Single Linkage wird der Abstand zweier Cluster als der **minimale Abstand** zwischen allen Paaren von Datenpunkten aus den beiden Clustern definiert:

$$D(C_1, C_2) = \min D(x_i, x_j) \quad \text{mit } x_i \in C_1, x_j \in C_2$$

Diese Methode erkennt langgezogene, nicht-sphärische Strukturen hervorragend – beispielsweise halbmondförmige oder kettenartige Anordnungen. Allerdings besteht die Gefahr des sogenannten **Chaining-Effekts**: Einzelne Brückenpunkte zwischen eigentlich getrennten Gruppen können dazu führen, dass Cluster unerwünscht zusammenwachsen.

2.2 Complete Linkage (Entferntester Nachbar)

Complete Linkage verwendet den **maximalen Abstand** zwischen Punktepaaaren zweier Cluster:

$$D(C_1, C_2) = \max D(x_i, x_j) \quad \text{mit } x_i \in C_1, x_j \in C_2$$

Diese Methode erzeugt kompakte, klar voneinander getrennte Cluster. Sie neigt dazu, große Cluster aufzubrechen, anstatt sie über dünne Verbindungen zusammenzuführen. Ein Nachteil ist die **Empfindlichkeit gegenüber Ausreißern**: Ein einzelner weit entfernter Punkt kann den Abstand zwischen zwei Clustern künstlich vergrößern und die Verschmelzung verhindern.

2.3 Average Linkage (Mittlerer Abstand)

Average Linkage berechnet den **Durchschnitt aller paarweisen Abstände** zwischen den Punkten beider Cluster:

$$D(C_1, C_2) = (1/|C_1| \cdot 1/|C_2|) \sum \sum D(x_i, x_j)$$

Als Kompromiss zwischen Single und Complete Linkage erweist sich Average Linkage in vielen Fällen als robuster Allrounder. Die Methode ist weniger anfällig für den Chaining-Effekt und gleichzeitig toleranter gegenüber Ausreißern als Complete Linkage.

2.4 Centroid-Methode

Die Centroid-Methode definiert den Clusterabstand als den **euklidischen Abstand zwischen den Schwerpunkten (Zentroiden)** der beiden Cluster. Nach jeder Verschmelzung wird der Schwerpunkt des neuen Clusters als gewichtetes Mittel neu berechnet.

Ein bekanntes Problem dieser Methode sind sogenannte **Inversionen** im Dendrogramm: Es kann vorkommen, dass ein Verschmelzungsschritt auf einer niedrigeren Distanzebene stattfindet als ein vorheriger Schritt. Dies erschwert die Interpretation des Dendrogramms erheblich und macht die Centroid-Methode in der Praxis weniger beliebt als Ward's Method oder Average Linkage.

2.5 Ward's Methode (Minimum-Varianz)

Ward's Methode verfolgt einen varianzbasierten Ansatz: In jedem Schritt werden diejenigen beiden Cluster verschmolzen, bei denen der **Zuwachs der gesamten Innerhalb-Cluster-**

Varianz (Within-Cluster Sum of Squares) minimal ist. Formal wird die Verschmelzung gewählt, die die Zielfunktion

$$\Delta(C_1, C_2) = (n_1 \cdot n_2) / (n_1 + n_2) \cdot ||m_1 - m_2||^2$$

minimiert, wobei m_1 und m_2 die Schwerpunkte und n_1, n_2 die Größen der Cluster bezeichnen.

Wichtiger Hinweis: Ward's Methode setzt zwingend die Verwendung der **quadrierten euklidischen Distanz** voraus. Die Kombination mit anderen Distanzmaßen (z. B. Manhattan- oder Kosinus-Distanz) ist mathematisch nicht korrekt und führt zu verfälschten Ergebnissen. In der Praxis ist Ward's Methode die am häufigsten eingesetzte Linkage-Methode, da sie gleichmäßig große, kompakte und sphärische Cluster erzeugt.

3 Das Dendrogramm

Das Dendrogramm ist die zentrale Visualisierung des hierarchischen Clustering-Prozesses. Es stellt die gesamte Verschmelzungshistorie als Baumstruktur dar und ermöglicht die nachträgliche Bestimmung einer geeigneten Clusteranzahl.

Achsen und Interpretation

Die **x-Achse** zeigt die einzelnen Datenpunkte (z. B. Beobachtungen, Länder, Kunden). Die **y-Achse** gibt die Distanz an, bei der eine Verschmelzung stattgefunden hat. Je höher der waagerechte Verbindungsbalken zwischen zwei Ästen liegt, desto unähnlicher waren die verschmolzenen Gruppen zum Zeitpunkt ihrer Vereinigung.

Bestimmung der optimalen Clusteranzahl k

Eine bewährte Heuristik zur Bestimmung der Clusteranzahl ist die Suche nach dem längsten vertikalen Abschnitt im Dendrogramm, der von keiner horizontalen Verschmelzungslinie geschnitten wird. Dieser Abschnitt repräsentiert den größten Sprung in der Distanz und deutet auf eine natürliche Trennlinie hin. Zieht man an dieser Stelle gedanklich eine horizontale Linie (den sogenannten „Cut“), ergibt die Anzahl der vertikalen Äste, die geschnitten werden, die empfohlene Clusteranzahl k .

Ergänzend können quantitative Kriterien wie der Silhouette-Koeffizient, der Elbow-Plot der Agglomerationsdistanzen oder der Calinski-Harabasz-Index herangezogen werden, um die Wahl von k statistisch zu untermauern.

4 Workflow (Best Practice)

4.1 Datenvorbereitung

1. **Labels sichern:** Bezeichnungen wie Ländernamen oder Kunden-IDs sollten als Index oder Metadaten gespeichert, aber nicht als numerische Features in die Berechnung einfließen.
2. **Skalierung (StandardScaler):** Alle numerischen Merkmale müssen standardisiert werden ($\mu = 0, \sigma = 1$), damit Features mit großen Wertebereichen (z. B. Umsatz in Tausend) nicht die Distanzberechnung dominieren. Dies ist eine der häufigsten Fehlerquellen beim hierarchischen Clustering.
3. **Fehlende Werte behandeln:** Distanzmaße erfordern vollständige Datensätze. Fehlende Werte müssen vor der Modellierung durch Imputation oder Ausschluss behandelt werden.

4.2 Modellierung

Wählen Sie zunächst ein geeignetes **Distanzmaß** (für metrische Daten in der Regel die euklidische Distanz; für binäre Merkmale z. B. die Jaccard-Distanz). Entscheiden Sie anschließend über die **Linkage-Methode**: Ward's Methode ist die Standardwahl für kompakte Cluster; bei nicht-sphärischen Strukturen sollte Single oder Average Linkage in Betracht gezogen werden.

4.3 Analyse und Interpretation

Plotten Sie das Dendrogramm und setzen Sie den Cut an der Stelle mit dem größten Distanzsprung. Spielen Sie die Cluster-Zuordnung an die Originaldaten zurück und berechnen Sie Gruppen-Mittelwerte (Profiling), um die inhaltliche Bedeutung jedes Clusters zu interpretieren.

5 Algorithmenvergleich

Die Wahl des Clustering-Verfahrens hängt von mehreren Faktoren ab. Die folgende Tabelle stellt die drei gängigsten Verfahren gegenüber:

Kriterium	Hierarchisch	K-Means	DBSCAN
Datenmenge	Klein bis mittel (< 10.000 Zeilen)	Groß (Millionen)	Klein bis groß
Clusteranzahl	Wird explorativ aus Dendrogramm abgeleitet	Muss vorab als k festgelegt werden	Ergibt sich automatisch
Clusterform	Abhängig von der Linkage-Methode	Nur sphärische Cluster (Voronoi-Zellen)	Beliebige Formen
Umgang mit Ausreißern	Werden regulären Clustern zugeordnet	Verzerren die Zentroide	Werden als Rauschen klassifiziert
Laufzeit	$O(n^2 \log n)$ bis $O(n^3)$	$O(n \cdot k \cdot t)$ Linear skalierbar	$O(n \log n)$ mit Indexstruktur

Korrekturhinweis zum Originalskript: Die dort angegebene Beschränkung von DBSCAN auf „mittlere“ Datenmengen ist ungenau. Mit geeigneter räumlicher Indexierung (z. B. KD-Trees) skaliert DBSCAN auf $O(n \log n)$ und ist damit auch für größere Datensätze geeignet. Außerdem wurde die Laufzeitkomplexität für alle drei Verfahren ergänzt, da diese für die praktische Methodenwahl relevant ist.

6 Häufige Fehlerquellen

1. Vergessene Skalierung

Wenn ein Feature Werte im Bereich von 1.000 aufweist und ein anderes im Bereich von 0,5, dominiert das nicht-skalierte Feature die Distanzberechnung vollständig. Lösung: Immer StandardScaler (oder MinMaxScaler bei nicht-normalverteilten Daten) vor dem Clustering anwenden.

2. Unpassende Linkage-Methode

Ward's Methode auf halbmondförmige Daten angewendet zerschneidet die natürliche Struktur, da sie sphärische Cluster bevorzugt. Umgekehrt erzeugt Single Linkage auf kompakten, kugelartigen Daten unerwünschte Kettenstrukturen. Die Linkage-Methode sollte stets auf die erwartete Geometrie der Daten abgestimmt werden.

3. Target Leakage

Die abhängige Variable (Target) darf nicht als Feature in das Clustering einfließen, da dies die Cluster künstlich nach dem Ergebnis ausrichtet. Das Target dient ausschließlich der nachträglichen Validierung und Interpretation der gefundenen Gruppen.

4. Falsches Distanzmaß bei Ward's Methode

(Ergänzung zum Originalskript) Ward's Methode setzt die quadrierte euklidische Distanz voraus. Die Verwendung anderer Distanzmaße (Manhattan, Kosinus, etc.) verletzt die mathematischen Annahmen und führt zu fehlerhaften Ergebnissen. Viele Softwarepakete verwenden diese Kombination jedoch standardmäßig korrekt.

7 Zusammenfassung

Hierarchisches Clustering ist ein vielseitiges, exploratives Verfahren, das insbesondere dann seine Stärken ausspielt, wenn die Clusteranzahl unbekannt ist und die Datenstruktur visuell untersucht werden soll. Die Wahl der Linkage-Methode hat entscheidenden Einfluss auf das Ergebnis und sollte stets bewusst und datengetrieben erfolgen. In Kombination mit sorgfältiger Datenvorbereitung – vor allem der Skalierung – und einer strukturierten Ergebnisinterpretation liefert das Verfahren zuverlässige und interpretierbare Gruppenstrukturen.

Für große Datensätze oder spezielle Anforderungen (beliebige Clusterformen, Ausreißerbehandlung) sollte stets geprüft werden, ob alternative Verfahren wie K-Means, DBSCAN oder HDBSCAN besser geeignet sind.