



PCA

Umgang mit komplexen Datensätzen

Workshop LFT KI 24.1.2023:
Hauptkomponentenanalyse





Das Problem

Diabetes-Datensatz in Orange Data Mining

Pregnancies	Glucose	Blood Pressure	Skin Thickness	Insulin	BMI	Diabetes Pedigree Function	Age	Outcome
6	148	72	35	0	336	627	50	1
1	85	66	29	0	266	351	31	0
8	183	64	0	0	233	672	32	1
1	89	66	23	94	281	167	21	0
0	137	40	35	168	431	2288	33	1
5	116	74	0	0	256	201	30	0
3	78	50	32	88	31	248	26	1
10	115	0	0	0	353	134	29	0
2	197	70	45	543	305	158	53	1
8	125	96	0	0	0	232	54	1

Wie trainiert man da ein Modell, bzw. trifft eine Aussage?

DON'T BE SCARED OF NUMEROUS VARIABLES



PCA IS HERE TO HELP




Wäre es nicht toll, wenn man Daten ‚komprimieren‘ könnte?

- um die wichtigen von den unwichtigen Features zu unterscheiden?
 - Und wenn man die unwichtigen Features wegnimmt, so hat man die Komplexität der Daten verringert
 - Was gleichbedeutend mit einer „**Dimensionsreduktion**“ ist.
 - Quasi eine Art „Rauschunterdrückung“ für Daten?
-
- ... Dann wären Daten leichter interpretierbar / visualisierbar.
 - ... Modelle könnten leichter trainiert werden.
 - ... und würden auch schneller laufen.
 - ... und dabei sogar noch weniger Speicher benötigen.

Und das alles für numerische, Bild- und Textdaten?


ME WHEN



**MRS. JACOBS USES SO MUCH BIG
VOCABULARY WORDS THAT I DON'T
UNDERSTAND**

„Was die SuS am Ende der Stunde verstanden haben sollten ...“

Sammlung von wichtigen Konzepten und Begriffen:




Universitätsniveau ... nicht für SuS – aber für Lehrer

Intuitives Konzept:

Die PCA kann man sich als Anpassung eines (n -dimensionalen) Ellipsoids an die Daten vorstellen, wobei jede Achse des Ellipsoids eine Hauptkomponente darstellt.


Wenn eine Achse des Ellipsoids klein ist, dann ist auch die Varianz entlang dieser Achse klein.



PC₁, PC₂ sind die Eigenvektoren der Kovarianzmatrix.


Die Länge der Eigenvektoren entspricht den Eigenwerten.

Je größer der Eigenwert, desto 'bedeutsamer' Eigenvektor.



Wie funktioniert PCA?


PCA in a nutshell





Josh Starmer on Statquest explaining the main idea of pca:

Range of
4:05 – 9:25
(1.25x speed)



<https://www.youtube.com/watch?v=FgakZw6K1QQ&t=1o86s>
<https://www.youtube.com/watch?v=WBlnwvjfMtQ>



<https://chat.openai.com/chat>

Fragen wir die GPT mit Internetsuche!

- Datenzentrierung:** Zunächst werden die Daten so transformiert, dass der Mittelwert jeder Variablen null ist. Dies geschieht durch Subtraktion des Mittelwerts jeder Variablen von den entsprechenden Datenpunkten.

- Kovarianzmatrix berechnen:** Nach der Zentrierung wird die Kovarianzmatrix der Daten berechnet. Diese Matrix gibt an, wie stark die Variablen miteinander variieren und hilft dabei, die Beziehungen zwischen ihnen zu verstehen.

Eigenwerte und Eigenvektoren bestimmen: Anschließend werden die Eigenwerte und die zugehörigen Eigenvektoren der Kovarianzmatrix ermittelt. Die Eigenvektoren repräsentieren die Richtungen der Hauptkomponenten, während die Eigenwerte die Varianz entlang dieser Komponenten angeben.

Hauptkomponenten auswählen: Die Eigenvektoren werden nach den Werten ihrer Eigenwerte sortiert, wobei die größte Varianz zuerst kommt. Die Hauptkomponenten mit den größten Eigenwerten werden ausgewählt, um die Daten in einen niedrigerdimensionalen Raum zu projizieren, wobei möglichst viel der ursprünglichen Varianz erhalten bleibt.

ONE DOES NOT SIMPLY

UNDERSTAND PCA

makeameme



Selber machen mit Orange Data Mining

Gute Datensätze zum Einstieg:

- Zoo
- Diabetes (Indian)
- Weinsorten
- Iris (wie immer...)
- Selbst gemalte Daten
- Breast Cancer Wisconsin