

Der ADF-Test (Augmented Dickey-Fuller)

Grundverständnis und praktischer Einsatz in der Zeitreihenanalyse

1 Das Ausgangsproblem: Stationarität

Viele Verfahren der Zeitreihenanalyse (z. B. ARIMA-Modelle) setzen voraus, dass die Daten **stationär** sind. Das bedeutet vereinfacht: Die Zeitreihe schwankt um einen festen Mittelwert und verhält sich statistisch über die Zeit gleich.

Zur Erinnerung (Leitfaden Block 3) müssen dafür drei Bedingungen erfüllt sein:

Bedingung	Was heißt das?	Gegenbeispiel
Konstanter Mittelwert	Die Reihe pendelt immer um denselben Wert	Aufsteigender Trend
Konstante Varianz	Die Schwankungsbreite bleibt gleich	Immer größere Ausräge
Konstante Autokovarianz	Der Zusammenhang zwischen aufeinanderfolgenden Werten ändert sich nicht	Sich ändernde Korrelation

Ein **Random Walk** dagegen erbt den vorigen Wert komplett und addiert nur zufälliges Rauschen. Schocks verpuffen nicht, sie häufen sich an – die Reihe wandert. Man sagt: sie hat eine **Einheitswurzel (Unit Root)**.

Kernfrage: Gegeben eine Zeitreihe – ist sie stationär, oder hat sie eine Einheitswurzel? Der ADF-Test beantwortet genau diese Frage.

2 Was macht der ADF-Test?

Der ADF-Test prüft statistisch, ob eine Zeitreihe stationär ist oder nicht. Dabei funktioniert er wie ein Hypothesentest, den Sie schon aus der Statistik kennen:

	Hypothese	Bedeutung
H_0	Einheitswurzel vorhanden	Nicht stationär (die „schlechte Nachricht“)
H_1	Keine Einheitswurzel	Stationär (die „gute Nachricht“)

Achtung – umgekehrte Logik! H_0 ist hier die „schlechte“ Annahme (nicht stationär). Ein kleiner p-Wert ist deshalb ein **gutes** Ergebnis, weil er H_0 verwirft und Stationarität nahelegt.

Was passiert intern? Der Test berechnet eine Teststatistik und vergleicht sie mit speziellen kritischen Werten (der sogenannten Dickey-Fuller-Verteilung). Daraus ergibt sich ein p-Wert. Die Python-Funktion `adfuller()` erledigt das alles automatisch – Sie müssen die Berechnung nicht selbst durchführen.

Wichtig: Der ADF-Test verwendet *nicht* die normale t-Verteilung, sondern eine eigene, nach links verschobene Verteilung. Die Funktion `adfuller()` berücksichtigt das automatisch. Deshalb sollten Sie immer die Bibliotheksfunktion nutzen und nicht manuell mit t-Werten vergleichen.

2.1 Einstellungen für den Test

Der ADF-Test kann optional berücksichtigen, ob die Zeitreihe um einen Mittelwert oder um einen Trend schwankt. Das steuert man über den Parameter `regression`:

Python-Parameter	Wann verwenden?
<code>regression='c'</code>	Standardeinstellung – passt für die meisten Fälle (Reihe schwankt um einen Mittelwert)
<code>regression='ct'</code>	Wenn die Reihe einen sichtbaren linearen Trend hat
<code>regression='n'</code>	Nur wenn die Reihe offensichtlich um 0 schwankt (selten)

Analogie: Stellen Sie sich vor, Sie wollen testen, ob ein Kind Fieber hat. Aber das Kind war draußen in der Sonne, und die Temperatur steigt allein deswegen. Wenn Sie den Sonneneffekt nicht rausrechnen, denken Sie fälschlicherweise „Fieber!“. Der Parameter 'ct' rechnet solche Trendeffekte raus.

3 Ablauf in der Praxis

3.1 Schritt für Schritt

Schritt	Aktion
1	Zeitreihe plotten. Visuell prüfen: Wandert sie? Hat sie einen Trend?
2	ADF-Test durchführen: <code>adfuller(x, regression='c')</code>
3	p-Wert ablesen
4a	$p < 0,05 \rightarrow H_0$ verworfen $\rightarrow$ Reihe ist stationär $\rightarrow$ direkt modellieren
4b	$p \geq 0,05 \rightarrow$ Reihe differenzieren (Δx bilden) und bei Schritt 2 wiederholen

3.2 Python-Code

```
from statsmodels.tsa.stattools import adfuller

ergebnis = adfuller(x, regression='c')

adf_statistik = ergebnis[0] # z.B. -2.26
p_wert        = ergebnis[1] # z.B. 0.184
krit_werte    = ergebnis[4] # kritische Werte
```

Entscheidungsregel: $p < 0,05 \rightarrow$ stationär. So einfach ist es in der Praxis.

4 Wozu differenziert man?

Wenn der ADF-Test sagt „nicht stationär“, muss man die Reihe **differenzieren** (vgl. Leitfaden Block 5). Dabei wird statt der Originalwerte die **Veränderung** von Zeitschritt zu Zeitschritt betrachtet: $\Delta x = x_t - x_{t-1}$.

Aber warum? Ein reiner Random Walk wäre tatsächlich nicht vorhersagbar. Reale Zeitreihen sind aber selten rein zufällig. Typischerweise überlagern sich verschiedene Komponenten (vgl. Leitfaden Block 2, Dekomposition):

Komponente	Beispiel	Stationär?
Niveau (Level)	Umsatz liegt bei ca. 100k €	Kann wandern $\rightarrow$ oft nicht stationär
Trend	Umsatz steigt jedes Jahr um 5 %	Systematischer Anstieg $\rightarrow$ nicht stationär
Saisonalität	Dezember-Umsatz immer höher	Wiederkehrend $\rightarrow$ vorhersagbar
Rauschen	Zufällige Schwankungen	Stationär

Differenzieren entfernt das wandernde Niveau und legt die **Veränderungsmuster** frei. „Im Dezember steigt der Umsatz immer um ca. X“ ist eine Aussage über die Veränderung Δx , nicht über den Absolutwert x .

Merksatz: Differenzieren ist kein Selbstzweck, sondern der Schritt, der die modellierbaren Muster sichtbar macht. Der Parameter d in $ARIMA(p,d,q)$ gibt die Anzahl der nötigen Differenzierungen an (Leitfaden Block 9). Der ADF-Test sagt Ihnen, ob dieser Schritt nötig ist.

4.1 Entscheidungstabelle

Situation	Was tun?
-----------	----------

ADF sagt „stationär“	Direkt modellieren (z. B. ARMA)
ADF sagt „Einheitswurzel“	Differenzieren (Δx bilden), erneut testen
Differenzierte Reihe ist stationär	Auf Δx modellieren → ARIMA-Modell
Auch nach Differenzierung nicht stationär	Nochmals differenzieren (selten nötig, $d \geq 3$ kommt praktisch nie vor)

5 Zusammenfassung

Der ADF-Test in drei Sätzen

1. Der ADF-Test prüft, ob eine Zeitreihe stationär ist oder eine Einheitswurzel hat.
2. Ist der p-Wert $< 0,05$, wird H_0 verworfen und die Reihe gilt als stationär.
3. Ist die Reihe nicht stationär, wird differenziert und erneut getestet. Das Ergebnis bestimmt den Parameter d im ARIMA-Modell.

Hinweis: Das begleitende Jupyter-Notebook zeigt alle Schritte mit konkreten Daten und Python-Code.