

Pruning in Machine Learning

1 · Kernidee

Definition

Pruning (engl. *to prune* = beschneiden) = das **gezielte Entfernen von Modellteilen, die wenig zur Vorhersage beitragen** — um Overfitting zu verringern, Modelle kleiner/schneller zu machen und besser interpretierbar zu halten.

Derselbe Grundgedanke, drei Kontexte — was entfernt wird, unterscheidet sich:

Kontext	Was wird entfernt?	Hauptziel	Wann?
Entscheidungsbaum / Forest	Knoten / Teilbäume	weniger Overfitting	vor/nach Training
Neuronales Netz	Gewichte / Neuronen	Kompression & Tempo	meist nach Training
Optuna (HP-Suche)	aussichtslose Trials	Rechenzeit sparen	während der Suche

2 · Entscheidungsbaum-Pruning

Pre-Pruning (vorab bremsen): `max_depth`, `min_samples_leaf`, `min_impurity_decrease`.

Post-Pruning (voll wachsen lassen, dann zurückschneiden): Standard ist **Cost-Complexity Pruning (CCP)** über den Parameter `ccp_alpha`.

Kostenmaß

Formel: $R\alpha(T) = R(T) + \alpha \cdot \tilde{T}$

- $R(T)$ = Fehler-/Impuritätssumme (kleiner = besser)
- $\tilde{T}$ = Anzahl Blätter (= Modellkomplexität)
- $\alpha \geq 0$ = Strafpreis pro Blatt — größer $\Rightarrow$ stärker beschnitten

Rechenbeispiel — wann lohnt sich ein Schnitt?

 **Effektives α** $\alpha_{\text{eff}} = (R(\text{Knoten als Blatt}) - R(\text{Teilbaum})) / (\tilde{T} - 1)$

Teilbaum: 3 Blätter, Fehler $R = 0,02$. Als ein Blatt zusammengefasst: $R = 0,08$.

$\alpha_{\text{eff}} = (0,08 - 0,02) / (3 - 1) = 0,06 / 2 = \mathbf{0,03}$

Interpretation: $\alpha < 0,03 \Rightarrow$ Teilbaum bleibt. $\alpha \geq 0,03 \Rightarrow$ Teilbaum wird zu einem Blatt zusammengeschnitten.

Random Forest: Einzelbäume im Forest werden meist **nicht** beschnitten (Bagging dämpft Overfitting bereits). „Pruning“ heißt dort: ganze Bäume entfernen oder Wachstum begrenzen.

3 · Neuronales Netz — Magnitude Pruning

Idee: viele Gewichte liegen betragsmäßig nahe null und tragen kaum bei $\rightarrow$ die **betragskleinsten Gewichte hart auf 0 setzen**.

Variante	Was passiert?	Effekt
unstrukturiert	einzelne Gewichte $\rightarrow 0$	dünn besetzte Matrix (sparse)
strukturiert	ganze Neuronen / Filter raus	echt kleineres, schnelleres Netz

Rechenbeispiel — 50 % Sparsity

 **Schwelle = Median der Beträge**

$w = [0,81 \ -0,04 \ 0,55 \ 0,02 \ -0,77 \ 0,09 \ -0,01 \ 0,63]$

1. Beträge sortieren: 0,01 0,02 0,04 0,09 | 0,55 0,63 0,77 0,81

2. Schwelle (50 %-Quantil) $\approx 0,32$

3. alles mit $|w| < 0,32 \rightarrow 0$:

$w_{\text{pruned}} = [0,81 \ 0 \ 0,55 \ 0 \ -0,77 \ 0 \ 0 \ 0,63]$

$\Rightarrow$ die 4 kleinsten Gewichte fallen weg, die wichtigen Verbindungen bleiben.

Bezug zu „Optima“ — Lottery-Ticket-Hypothese

Die Genauigkeit bleibt oft bis **70–90 % Sparsity** nahezu konstant: In einem großen Netz steckt ein kleines „gewinnendes“ Teilnetz, das ein **ebenso gutes Optimum** repräsentiert. Pruning legt es frei.

In der Praxis (PyTorch)

```
import torch.nn.utils.prune as prune

# unstrukturiert, global, 70 % der betragskleinsten Gewichte:
params = [(net.fc1, 'weight'), (net.fc2, 'weight'), (net.fc3, 'weight')]
prune.global_unstructured(params,
                          pruning_method=prune.L1Unstructured,
                          amount=0.70)

# strukturiert (ganze Neuronen einer Schicht):
prune.ln_structured(net.fc1, name='weight', amount=0.3, n=2, dim=0)

prune.remove(net.fc1, 'weight') # Maske dauerhaft einbacken
```

4 · Optuna — Trial-Pruning

Kein Modellteil wird entfernt, sondern eine **aussichtslose Hyperparameter-Konfiguration früh abgebrochen**. Optuna meldet Zwischenergebnisse; der MedianPruner stoppt Trials unter dem bisherigen Median. Die gesparte Rechenzeit fließt in bessere Trials.

```
for step in range(n_steps):
    acc = train_one_step(...)
    trial.report(acc, step)          # Zwischenergebnis melden
    if trial.should_prune():         # aussichtslos?
        raise optuna.TrialPruned() # -> abbrechen

study = optuna.create_study(
    pruner=optuna.pruners.MedianPruner(n_startup_trials=5, n_warmup_steps=3))
```

Merksatz

Ein Modell ohne Pruning ist wie ein Aufsatz ohne Überarbeitung: es steht alles drin — auch das Überflüssige. Pruning streicht die Sätze, die nichts beitragen.