

Statistische Grundbegriffe für ML/KI

Kategorie	Begriff	Formel	Anwendungsfall	Erklärung	Zusammenhang
Lagemaße	Mittelwert (arithm. Mittel)	$\bar{x} = (1/n) \cdot \sum x_i$	Feature-Zentrierung, Baseline-Vorhersagen, Data Preprocessing	Der Durchschnitt aller Werte – Summe geteilt durch Anzahl. Empfindlich gegenüber Ausreißern.	→ Grundlage für Varianz
	Median	Mittlerer Wert der sortierten Daten (= Q_2 = 50%-Quartil)	Robuste Schätzung bei Ausreißern, Boxplot-Zentrum	Teilt die Daten in zwei gleich große Hälften. Robuster als Mittelwert bei schiefen Verteilungen.	= Q_2 im Boxplot
Streuungsmaße	Varianz (Population)	$\sigma^2 = (1/n) \cdot \sum (x_i - \bar{x})^2$	Risikomessung, Feature-Selektion, PCA	Mittlere quadrierte Abweichung vom Mittelwert. Einheit ist quadriert.	← Mittelwert; → Standardabweichung
	Stichprobenvarianz	$s^2 = (1/(n-1)) \cdot \sum (x_i - \bar{x})^2$	Schätzung der Populationsvarianz aus Stichproben	Bessel-Korrektur (n-1): Stichprobe unterschätzt systematisch die wahre Varianz; n-1 korrigiert diesen Bias.	← Korrektur der Varianz
	Standardabweichung	$\sigma = \sqrt{\sigma^2}$ bzw. $s = \sqrt{s^2}$	Normalverteilung, Anomalieerkennung, Konfidenzintervalle	Wurzel der Varianz – Streuung in Origineleinheit. Bei Normalverteilung: ~68% innerhalb $\pm 1\sigma$.	← $\sqrt{\text{Varianz}}$; → Nenner im Z-Score
	Spannweite (Range)	$R = x_{\text{max}} - x_{\text{min}}$	Schnelle Dateninspektion, Qualitätskontrolle	Differenz zwischen größtem und kleinstem Wert. Ausreißerempfindlich.	→ Alternative: robusterer IQR
	Quartile (Q_1, Q_2, Q_3)	Q_1 = 25%, Q_2 = 50% (Median), Q_3 = 75%	Boxplot-Konstruktion, Verteilungsanalyse	Teilen sortierte Daten in vier gleiche Teile. Q_1 und Q_3 bilden die Box im Boxplot.	→ $Q_3 - Q_1 = IQR$
	Interquartilsabstand (IQR)	$IQR = Q_3 - Q_1$	Boxplot-Konstruktion, Ausreißer-Erkennung	Enthält die mittleren 50% der Daten. Robust gegenüber Ausreißern.	← Q_1, Q_3 ; → definiert Whisker
	Whisker (Boxplot)	Bis max. $1,5 \times IQR$ ab Q_1/Q_3	Ausreißer-Visualisierung im Boxplot	Linien vom Boxrand bis zum letzten Datenpunkt innerhalb von $1,5 \times IQR$.	← IQR, Q_1, Q_3
Zusammenhangsmaße	Kovarianz	$cov(X,Y) = (1/n) \cdot \sum (x_i - \bar{x})(y_i - \bar{y})$	Richtung des Zusammenhangs, Grundlage für PCA	Misst gemeinsame Variation. Positiv = gleichgerichtet, negativ = gegenläufig.	← Mittelwerte; → Korrelation
	Korrelation (Pearson)	$r = cov(X,Y) / (\sigma_x \cdot \sigma_y)$	Feature-Auswahl, explorative Analyse	Standardisierte Kovarianz [-1, +1]. Misst Stärke des linearen Zusammenhangs.	← Kovarianz / Standardabweichungen
Standardisierung	Z-Score	$z = (x - \bar{x}) / \sigma$	Feature-Standardisierung, Ausreißer-Erkennung, Vergleichbarkeit	Anzahl Standardabweichungen vom Mittelwert. Macht unterschiedliche Skalen vergleichbar.	← Mittelwert, Standardabweichung
Verteilungseigenschaften	Schiefe (Skewness)	$\gamma = (1/n) \cdot \sum ((x_i - \bar{x})/\sigma)^3$	Verteilungsanalyse, Transformationsentscheidungen	Asymmetrie der Verteilung. Positiv = rechtsschief, negativ = linksschief	← nutzt Z-Scores
	Erwartungswert	$E[X] = \sum x_i \cdot P(x_i)$	Theoretische Modellierung, Verlustfunktionen,	Wahrscheinlichkeitsgewichteter Durchschnitt – theoretischer Mittelwert	→ theoretisches Pendant zum Mittelwert
	Normalverteilung	$f(x) = (1/(\sigma\sqrt{2\pi})) \cdot e^{-(x-\mu)^2/(2\sigma^2)}$	Grundannahme vieler ML-Modelle, statistische Tests	Die "Glockenkurve" – vollständig durch μ (Mittelwert) und σ (Standardabweichung) beschrieben.	← definiert durch μ und σ