

Vom Bild zur Zeitreihe: das 1D-CNN

Zusammenfassung und Brücke zwischen der App und dem PyTorch-Notebook

Wo dieses Blatt steht

Erleben in der App (Zeitreihen-CNN-Labor) → **Sichern** mit diesem Merkblatt → **Anwenden** im Notebook (AirPassengers).

Kernidee in einem Satz: Ein 1D-CNN ist ein 2D-CNN mit nur einer Achse — der Zeit. Der Filter lernt Muster im Verlauf statt in der Fläche.

1 · Die Kernidee

Beim Bild-CNN gleitet ein kleiner Filter über Höhe und Breite und erzeugt eine Feature Map. Bei einer Zeitreihe gibt es nur eine Achse: die Zeit. Derselbe Filter gleitet nun über aufeinanderfolgende Zeitschritte und sucht nach Mustern im Verlauf — Anstieg, Spitze, saisonales Auf und Ab.

$x[t] \rightarrow [\text{Filter } w] \text{ gleitet über die Zeit } \rightarrow y[o] \text{ (Feature Map)}$

2 · Analogie 2D-CNN ↔ 1D-CNN

Konzept	2D-CNN (Bild)	1D-CNN (Zeitreihe)
Eingabe	Höhe × Breite (Pixelmatrix)	eine Zeitachse (Wertefolge)
Filter / Kernel	z. B. 3×3-Ausschnitt	z. B. 3 Zeitschritte
gleitet über	Fläche (2 Achsen)	Zeit (1 Achse)
PyTorch-Baustein	Conv2d / MaxPool2d	Conv1d / MaxPool1d
Tensor-Form	(Bilder, Kanal, Höhe, Breite)	(Fenster, Kanal, Zeitschritte)
Ergebnis	Feature Map (Fläche)	Feature Map (Verlauf)
rezeptives Feld	Kantenlänge des Kernels	Länge des Kernels
Normalisierung	Pixel / 16 → 0...1	MinMaxScaler → 0...1
Datenaufteilung	zufällig mischen ist ok	chronologisch — Mischen = Datenleck
Ziel / Ausgabe	Klasse (Softmax, Accuracy)	Zahl (Regression, MSE/MAE)

3 · Der eigentliche Unterschied: die Datenaufbereitung

Nicht das Netz unterscheidet Zeitreihen von Bildern, sondern die Vorbereitung der Daten. Zwei Punkte sind entscheidend:

1 · Chronologischer Split, kein Mischen. Mischt man die Fenster zufällig wie Bilder, lernt das Modell aus der Zukunft, um die Vergangenheit vorherzusagen — ein Datenleck. Deshalb: die ersten Monate zum Trainieren, die letzten (nie gesehenen) zum Testen.

2 · Normalisierung nur auf Train. Der Skalierer wird ausschließlich auf den Trainingsdaten gefittet und dann auf alles angewendet. Sonst sickert Testinformation ins Modell.

Nebenbei: Anders als bei SARIMA ist Stationarität für ein CNN nicht zwingend — sie hilft dem Training aber.

4 · Vokabel-Anker

Begriff	Bedeutung
Fenster (Window)	Feste Zahl vergangener Zeitschritte, die als eine Eingabe dienen (im Notebook: 12 Monate → 13. Monat).
Feature Map	Ausgabe eines Filters entlang der Zeit — der „gefilterte“ Verlauf.

Begriff	Bedeutung
Kanal (Channel)	Parallele Merkmalsreihe. Hier 1 (Passagierzahl); bei multivariaten Reihen mehrere.
rezeptives Feld	Wie viele Eingabe-Zeitschritte einen Ausgabewert beeinflussen (= Kernelgröße; wächst durch gestapelte Schichten).
kausal	Der Filter blickt nur in die Vergangenheit — nötig, damit ein Forecast nicht in die Zukunft schummelt.
Normalisierung auf Train	Skalen-Parameter (Min/Max) nur aus den Trainingsdaten gewinnen.

5 · Lohnt sich das 1D-CNN überhaupt?

Ihr kennt SARIMAX und Prophet. Ein 1D-CNN ist nicht automatisch besser — es kommt auf die Datenstruktur an.

1D-CNN spielt seine Stärke aus bei...	Klassik (SARIMAX/Prophet) oft besser bei...
multivariaten Reihen (viele Kanäle)	einzelnen, kurzen Reihen
nichtlinearen Mustern / Regimewechseln	überwiegend linearen Zusammenhängen
vielen ähnlichen Reihen (ein Modell für alle)	einer Reihe mit klarer Saisonalität/Trend
langen Abhängigkeiten (tiefe, gestapelte Filter)	wenn Interpretierbarkeit im Vordergrund steht

Faustregel: Bevor ein Modell überzeugt, muss es die naive Baseline schlagen — die simple Vorhersage „morgen = heute“ ($y[t+1] = y[t]$). Schlägt das CNN sie nicht, lohnt der Aufwand nicht.

6 · App ↔ Notebook ↔ Fachbegriff

Dieselbe Sache in drei Sprachen — so passen Screenshot, Code und Tafelbild zusammen:

In der App	Im Notebook	Fachbegriff
Signal + gleitendes Fenster (Konzept-Lab)	Abschnitt 3 · <code>erstelle_fenster()</code>	Sliding Window / Fenster
Filter + $\sum x \cdot w$ (Konzept-Lab)	Abschnitt 6 · <code>nn.Conv1d</code>	Faltung → Feature Map
Train/Val/Test farbig (Training-Lab)	Abschnitt 4 · zeitlicher Split	chronologische Aufteilung
Verlustkurve (Training-Lab)	Abschnitt 8 · <code>MSELoss</code> + Adam	Verlust / Optimierung
Gelernte Filter als Wellenformen	Abschnitt 11 · Filter vorher/nachher	gelernte Muster
Forecast vs. Wahrheit (Training-Lab)	Abschnitt 12 · Vorhersage-Plot	Evaluation / Generalisierung

Hinweis für den direkten Vergleich: Die App nutzt kausale Faltung und Flatten ohne Pooling; das Notebook nutzt „same“-Padding, `MaxPool1d` und eine Dense-Zwischenschicht. Zwei Varianten desselben Bausteinkastens — Pooling kennt ihr bereits aus dem 2D-CNN.

Merksatz

Der entscheidende Unterschied liegt nicht im Netz, sondern in der Datenaufbereitung — und in der ehrlichen Frage, ob das Modell die einfache Baseline überhaupt schlägt.